

UNIVERSIDADE DE SÃO PAULO

Instituto de Ciências Matemáticas e de Computação

Felipe Batista de Souza

Monografia - MBA em Ciências de Dados (CEMEAI)

Análise de Inadimplência para
Corretora de Seguros

Feline Batista

Felipe Batista

Análise de Inadimplência para Corretora de Seguros

Monografia apresentada ao Centro de Ciências Matemáticas Aplicadas à Indústria do Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo - ICMC/USP, como parte dos requisitos para obtenção do título de Especialista em Ciências de Dados.

Área de concentração: Ciências de Dados

Orientador: Prof. Dr. Diego Raphael

USP - São Carlos

2025

Esta página deve conter a ficha catalográfica e deve ser impressa no verso da folha de rosto.

Para elaborar, acesse o endereço:

<https://www.icmc.usp.br/institucional/estrutura-administrativa/biblioteca/servicos/ficha>

ou procure um bibliotecário na Seção de Atendimento ao Usuário da Biblioteca do ICMC

RESUMO

BATISTA, Felipe **Análise de Inadimplência para Corretora de Seguros.** 2025. Monografia (MBA em Ciências de Dados) – Centro de Ciências Matemáticas Aplicadas à Indústria, Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos, 2025.

Este trabalho tem como objetivo aplicar técnicas de estatística e machine learning em dados de uma corretora de seguros para prever a inadimplência em parcelas de seguros no contexto de negócios entre empresas (B2B). Foram testados modelos consagrados na literatura, como Regressão Logística, Random Forest e XGBoost, para avaliar sua viabilidade no dataset da empresa. Diante do desafio de dados desbalanceados, foram utilizadas técnicas de reamostragem aleatória, como oversampling e undersampling, para equilibrar as classes e melhorar o desempenho dos modelos. O desempenho foi avaliado por meio de métricas como recall, precisão, F1-score e pela análise da matriz de confusão, que permitiu visualizar a proporção de acertos e erros. Os resultados indicaram que o XGBoost com oversampling apresentou o melhor desempenho, destacando-se pela capacidade de capturar casos de inadimplência e reduzir falsos negativos, embora ainda haja espaço para melhorias, como o ajuste de hiperparâmetros e a busca por dados mais informativos. Conclui-se que, embora os modelos não estejam prontos para produção, eles oferecem um caminho promissor para auxiliar a empresa na gestão de riscos e na tomada de decisões estratégicas.

Palavras-chave: Previsão de inadimplência, Machine Learning, Regressão Logística, Random Forest, XGBoost, Dados desbalanceados, Oversampling, Undersampling, Recall, Precisão, F1-score, Matriz de confusão, Corretora de seguros.

ABSTRACT

BATISTA, Felipe. **Default Analysis for Insurance Broker**: subtitle. 2025. Monografia (MBA em Ciências de Dados) – Centro de Ciências Matemáticas Aplicadas à Indústria, Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos, 2020.

This study aims to apply statistical and machine learning techniques to data from an insurance brokerage to predict delinquency in insurance installments for business-to-business (B2B) transactions. Established techniques from previous works were tested to evaluate their feasibility on the company's dataset. Models such as Logistic Regression, Random Forest, and XGBoost were implemented, addressing the challenge of imbalanced data through random resampling techniques like *oversampling* and *undersampling*. Model performance was assessed using metrics such as recall, precision, F1-score, and the visualization of accuracy and error rates through the confusion matrix. The results indicated that XGBoost with *oversampling* achieved the best performance, excelling in capturing delinquency cases and reducing false negatives. However, further improvements are needed, including hyperparameter tuning and the acquisition of more informative data. Although the models are not yet ready for production, they show promising potential to assist the company in risk management and strategic decision-making.

Keywords: Default Prediction, Machine Learning, Logistic Regression, Random Forest, XGBoost, Unbalanced Data, Oversampling, Undersampling, Recall, Precision, F1-score, Confusion Matrix, Insurance Broker.

Sumário

Lista de Figuras.....	12
Lista de Tabelas.....	13
1 INTRODUÇÃO.....	14
2 REVISÃO BIBLIOGRÁFICA.....	17
3 Fundamentação teórica.....	19
3.1 Inadimplência.....	19
3.2 Modelos.....	19
3.2.1 Regressão Logística.....	19
3.2.2 Machine Learning.....	20
3.2.2.1 Randon Forest.....	21
3.2.2.2 XGBoost.....	23
3.3 Balanceamento de dados.....	25
3.3.1 Undersampling.....	26
3.3.2 Oversampling.....	27
3.3.3 Oversampling + Undersampling.....	28
3.4 Métricas de desempenho.....	28
4 Resultados.....	30
4.1 Análise exploratória.....	30
4.2 Avaliação dos modelos.....	33
4.2.1 Modelos com dados desbalanceados.....	34
4.2.2 Modelos Undersampling.....	37
4.2.3 Modelos Oversampling.....	39
5 Conclusão.....	44
Referências.....	45

Lista de Figuras

Figura 1: Exemplo de estrutura de uma árvore de decisão.....	22
Figura 2: Distribuição de classes na base de dados do presente trabalho.....	26
Figura 3: Classes reamostradas utilizando o método de undersampling.....	27
Figura 4: Classes reamostradas utilizando a técnica de over-sampling.....	28
Figura 5: Exemplo de matriz de confusão. Fonte: Elaborado pelo autor.....	29
Figura 6: Distribuição de valor inadimplente. Fonte: De autoria própria.....	31
Figura 7: Análise trimestral de comissão inadimplente. Fonte: Autoria própria.....	32
Figura 8: Visão das colunas do dataset e seus respectivos tipos de dados.....	33
Figura 9: Matriz de confusão dados de validação Regressão Logística. Fonte: próprio autor.....	34
Figura 10: Matriz de confusão dados de teste Regressão Logística. Fonte: próprio autor.....	34
Figura 11: Matriz de confusão dados de validação Random Forest. Fonte: próprio autor.....	35
Figura 12: Matriz de confusão dados de teste Regressão Logística. Fonte: próprio autor.....	35
Figura 13: Matriz de confusão dados de validação XGBoosting. Fonte: próprio autor.....	36
Figura 14: Matriz de confusão dados de teste XGBoosting. Fonte: próprio autor.....	36
Figura 15: Matriz de confusão dados de validação Regressão Logística undersampling. Fonte: próprio autor.....	37
Figura 16: Matriz de confusão dados de teste Regressão Logística undersampling. Fonte: próprio autor.....	37
Figura 17: Matriz de confusão dados de validação Random Forest undersampling. Fonte: próprio autor.....	38
Figura 18: Matriz de confusão dados de validação Random Forest undersampling. Fonte: próprio autor.....	38
Figura 19: Matriz de confusão dados de validação XGBoost undersampling. Fonte: próprio autor.....	39
Figura 20: Matriz de confusão dados de teste XGBoost undersampling. Fonte: próprio autor.....	39
Figura 21: Matriz de confusão dados de validação Regressão Logística oversampling. Fonte: próprio autor.....	40
Figura 22: Matriz de confusão dados de teste Regressão Logística oversampling. Fonte: próprio autor.....	40
Figura 23: Matriz de confusão dados de validação Random Forest oversampling. Fonte: próprio autor.....	41
Figura 24: Matriz de confusão dados de teste Random Forest oversampling. Fonte: próprio autor.....	41
Figura 25: Matriz de confusão dados de validação XGBoost oversampling. Fonte: próprio autor.....	42
Figura 26: Matriz de confusão dados de teste XGBoost oversampling. Fonte: próprio autor.....	42

Lista de Tabelas

Tabela 1: Métricas de Desempenho de Modelos para Dados Desbalanceados: Acurácia, Precisão, Recall..... 36

Tabela 2: Métricas de Desempenho de Modelos para Dados Balanceados Undersampling: Acurácia, Precisão, Recall..... 39

Tabela 3: Métricas de Desempenho de Modelos para Dados Balanceados Oversampling: Acurácia, Precisão, Recall..... 42

Tabela 4: Métricas de Desempenho de Modelos: Acurácia, Precisão, Recall..... 43

1 INTRODUÇÃO

Toda a atividade humana envolve riscos que nos ameaçam, quer enquanto indivíduos quer coletivamente (VIEIRA, 2012, p. 14)

O risco é uma característica inerente à vida humana, estando presente em qualquer atividade que o ser humano deseje desenvolver, seja em contextos empresariais ou pessoais (VIEIRA, 2012). Presume-se que toda tarefa, por mais simples que pareça, envolva algum nível de risco. Existem ações que envolvem um risco muito menor, portanto, não é necessário tomar tanto cuidado, já outras são muito arriscadas e é nestes casos que a ideia de que a gestão e a avaliação de riscos são essenciais para minimizar possíveis impactos negativos e garantir a realização segura e eficaz dessas ações.

Caso não assumíssemos riscos, a vida seria maçante, pois é justamente a coragem de enfrentar desafios que impulsiona o progresso, tanto pessoal quanto tecnológico. Não há como viver em um esquema 100% seguro, já que até mesmo atividades básicas, como nos alimentarmos, envolvem riscos em todas as etapas. Desde a produção dos alimentos, passando pela criação de animais ou cultivo de vegetais, sua colheita ou abate, o transporte até nossas casas e o preparo final — seja com a chama do gás natural ou a eletricidade de um micro-ondas —, todos esses processos estão sujeitos a imprevistos. Em um contexto moderno, os riscos podem parecer menores, mas, se considerarmos como viviam nossos antepassados, fica evidente que a exposição ao perigo sempre foi uma constante na história humana.

Contudo, assim como a humanidade assume riscos para produzir e construir, também busca preservar-se, reduzindo esses riscos por meio da autoconservação. Estamos constantemente em busca de maneiras de nos mantermos o mais seguros possível. Um exemplo disso é o lojista que vende produtos a prazo apenas para clientes em quem confia, garantindo que receberá o valor devido. Da mesma forma, ao atravessar a rua, seguimos o conselho de nossas mães, olhando atentamente para ambos os lados a fim de evitar acidentes. Uma das estratégias que o ser humano desenvolveu para se proteger das incertezas da vida foi o resguardo financeiro, por meio dos seguros, que funcionam como uma forma de precaução contra imprevistos.

Os seguros são muito antigos, com suas origens datando de antes de Cristo. Os primeiros registros surgem por volta de 2250 a.C., há relatos de modelos de empréstimos, similares a seguros, que datam desta época (FARIAS, 2021). O famoso Código de Hamurabi, na antiga Mesopotâmia, continha leis de mutualismo que visavam proteger caravanas que não chegassem ao destino final (VIEIRA, 2012). Na Roma antiga, também, existia um sistema que previa o pagamento de indenizações aos familiares de soldados mortos em combate. (VIEIRA, 2012). Esse esquema de mutualismo permaneceu durante a Idade Média, sendo reconhecido pela Igreja Católica, que via o pagamento de algum dinheiro às famílias como uma forma de solidariedade (FARIAS, 2021).

Entretanto, não se pode afirmar que essas atividades constituíam uma estrutura de seguros como a conhecemos hoje, uma vez que não seguiam o modelo atual de transferência de risco para terceiros. Foi somente na Idade Média, durante as grandes navegações, que o processo de seguros evoluiu, permitindo que o risco fosse transferido para um “terceiro totalmente estranho à atividade arriscada” (VIEIRA, 2012, p. 16). Essa mudança marcou o início de um sistema mais próximo do

que entendemos como seguro na atualidade, onde a responsabilidade pelos riscos passou a ser compartilhada com entidades especializadas.

Nas grandes navegações, surgiram os “contratos de empréstimo marítimo” (VIEIRA, 2012), que transferiam o risco da viagem pelo mar, como a perda de mercadorias, para terceiros que cobravam um valor pela cobertura do risco durante a travessia. Para transportar mercadorias entre continentes, os comerciantes precisavam de grandes investimentos, uma vez que a empreitada era extremamente arriscada. Para proteger-se de possíveis perdas financeiras, tanto das mercadorias quanto dos empréstimos contraídos para financiar as viagens, os comerciantes pagavam um valor fixo. Em caso de naufrágio, eles recebiam um reembolso pela carga perdida, garantindo assim uma segurança financeira diante dos perigos do mar (VIEIRA, 2012).

No Brasil, a prática dos seguros chegou por volta do século XVIII, inicialmente através do mutualismo promovido pela Igreja Católica. Com o intuito de proteção como assistência moral e social, dando um caráter social a prática do mutualismo. Contudo, no final do século XVIII foi regulamentado a atividade com a exploração do comércio marítimo também (FARIAS, 2021).

Hoje, o uso de seguros se tornou uma das maiores áreas de atuação no Brasil e no mundo. No Brasil, o setor de seguros é essencial para qualquer empresa e também é crucial para a proteção individual. Com diversos tipos de seguro de vida e saúde e também de propriedade privada. Atualmente, mais de 14 milhões de pessoas utilizam seguros previdenciários, coletivos ou individuais, e mais de 51 milhões são beneficiários de seguros de assistência médica, representando 6,2% do PIB brasileiro. (“Folder Institucional CNseg - 2024 | CNseg”, [s.d.]).

Sendo uma área tão importante e com uma longa história, é fundamental que o setor de seguros se mantenha atualizado por meio da implementação de novas tecnologias. Atualmente, o uso de *data science* está em alta, com técnicas aplicadas em diversas áreas, incluindo seguros. Há muitos anos, mesmo antes de receber esse nome, modelos estatísticos já eram utilizados no setor para prever riscos e avaliar a viabilidade de criar apólices que atendam às necessidades de empresas ou pessoas físicas. Esses modelos também ajudam a determinar o valor do prêmio, que é o valor pago pelo segurado, e o sinistro, que é o valor a ser reembolsado em caso de ocorrência de um evento coberto. Dessa forma, a aplicação de tecnologias modernas, como *data science*, continua a ser essencial para aprimorar a eficiência e a precisão do setor de seguros.

Apesar dessas técnicas serem amplamente utilizadas, não há literatura disponível que trate especificamente da previsão de inadimplência na área de seguros. Mesmo após muita pesquisa, até o momento, não encontramos nada sobre este tema, seja em português ou inglês. É para isso que este trabalho se destina: desenvolver técnicas de previsão de inadimplência para segurados.

Este estudo visa explorar essa área ainda não investigada da classificação de inadimplência em dados de seguradoras. Antes de tudo, é interessante definir o que é uma corretora, pois os conceitos de seguradora e corretora muitas vezes se confundem.

Uma corretora nada mais é que “é o lugar que vende seguros” (TEIXEIRA, 2022). Para a contratação de uma apólice de seguros a presença da corretora é essencial. Ela é quem faz a intermediação entre a seguradora e o cliente. Ela que faz uma série de tramites legais para a criação da apólice e execução do sinistro.

Só destacando que seguradoras e corretoras são coisas diferentes. As seguradoras são as responsáveis por oferecer o serviço de seguro. Ela que oferece o produto em si. Para funcionarem, elas precisam de cadastro na Superintendência de Seguros Privados (Susep), a autarquia do governo federal que fiscaliza as companhias (TEIXEIRA, 2022).

Como dissemos anteriormente, as corretoras são as intermediárias, ou seja, é por meio delas que acontece a contratação do serviço. Os clientes pagam para as seguradoras assumirem o risco pela proteção de seus bens ou vidas e as corretoras que intermedeiam o processo através de vários processos de regulamentação (TEIXEIRA, 2022).

O presente estudo se propõe a analisar e prever a inadimplência de uma grande corretora brasileira (por motivos de confidencialidade, seu nome será omitido). Os dados disponíveis são exclusivos da corretora.

Todo o trabalho, com os códigos e os gráficos produzidos pode ser encontrado através do repositório no GitHub: https://github.com/Felisouza/tcc_mba_icmc

2 REVISÃO BIBLIOGRÁFICA

Durante a pesquisa sobre métodos estatísticos para análise de inadimplência, não foi encontrado estudos específicos sobre inadimplência no setor de corretoras de seguros. No entanto, selecionei alguns artigos em português e em língua inglesa que abordam o tema para explorar abordagens e modelos comuns. Optei por testar os técnicas mais comuns nesses estudos em uma base de dados diferente da utilizada pelos autores. A seguir, farei uma breve apresentação dos textos consultados.

Entre os trabalhos analisados, foram selecionados cinco para servir como base para o projeto, pois forneceram uma boa visão do campo de inadimplência em ciência de dados e abordaram questões que se relacionam com o conjunto de dados utilizado neste estudo, embora nenhum trate especificamente da inadimplência no setor de seguros. Esses artigos oferecem uma perspectiva sobre técnicas estatísticas que podem enriquecer e dar um norte para o projeto de pesquisa. Ajudando solucionar nosso problema de previsão de inadimplência de um cliente ou seguradora.

Todos os trabalhos aqui analisados seguem a mesma estrutura de estudo. Apresentam o problema, os modelos que escolheram utilizar, quais métricas vão usar para medir o desempenho de cada modelo, um comparativo entre os modelos e, por fim, qual o modelo tem o melhor desempenho e deve ser utilizado para aquele contexto específico que o autor propõe para solucionar aquele caso de inadimplência. Assim, como seguiremos neste presente trabalho de conclusão de curso de MBA.

(COELHO; AMORIM; CAMARGOS, 2021) analisam concessão de crédito para micro, pequenas e médias empresas do segmento de locação de automóveis no Brasil. O trabalho faz uma comparação método clássico de classificação, regressão logística contra outros dois modelos de *machine learning* *XGBoost* e *Randon Forest*. Para avaliar o desempenhos dos 3 modelos ele utilizou a acurácia, estatística Kolmogorov-Simirnov e a curva ROC. Os resultados obtidos pelo estudo apontaram que os métodos mais modernos, Randon Forest e XGBoost, tem um desempenho superior ao método clássico. Sendo que o XGBoost desempenhou melhor dentre todos.

É interessante notar que neste caso “quanto mais sofisticado o método estatístico adotado, maior foi a capacidade preditiva do modelo” (COELHO; AMORIM; CAMARGOS, 2021, p. 112). Mostrando que a evolução dos métodos estatísticos, de técnicas e desenvolvimento de novas tecnologias com poder de processamento superior conseguem superar métodos já vem estabelecidos.

O trabalho do (SANTOS, 2022) também compara algoritmos para analisar a concessão de crédito. Mas seu objeto de estudo é a concessão de crédito financeiro para pequenas empresas dos EUA vinculadas à entidade *US Small Business Administration (SBA)*. Ele também utilizou o método de análise estatística clássica do regressão logística e *random forest*, entretanto utilizou os modelos de *machine learning*, *Naive Bayes* e *Decision Tree*. Como métricas de avaliação ele utilizou as curvas AUC e ROC e as métricas de acurácia, *recall*, especificidade e precisão.

Vale destacar, deste trabalho, que ele enfrentou o problema dos dados desbalanceados. A proporção clientes adimplentes (cerca de 80%) e de inadimplentes era muito discrepante. Para isso ele teve que usar técnicas para tratar esse desbalanceamento. Usando *undersampling* e *oversampling* nos dados. Ele dividiu os modelos em três cenários diferentes: cenário real, modelos balanceados e com os modelos desbalanceados. Sendo “Os resultados encontrados apontam que a aplicação das técnicas de *Undersampling* e *Oversampling* ocasionou a redução da acurácia e sensibilidade na maior parte

dos modelos, porém gerou um aumento considerável da especificidade de todos os ajustes (...)” (SANTOS, 2022, p. 42). Sendo que os modelos desempenharam um papel melhor com a técnica de *oversampling* do que nos 2 outros cenários e o melhor modelo foi o *random forest*.

O trabalho de (MADAAN et al., 2021) também fala sobre análise de inadimplência de crédito bancário para pessoas físicas e também discute diferentes modelos para auxiliar os tomadores de decisão na concessão de crédito. Os modelos utilizados por eles são *Random Forest* e *Decision Tree*. Utilizando as métricas de precisão e *recall*, *f1score* os autores chegaram a conclusão, como é de se esperar, que *random forest* se saiu melhor nos testes.

Dentre os artigos analisados o trabalho mais recente sobre análise de crédito é o do (BARBAGLIA; MANZAN; TOSETTI, 2023) O estudo utilizou um dataset de hipotecas residenciais de vários países da Europa. Visando levantar a discussão sobre concessão de crédito imobiliário após a crise financeira dos Estados Unidos. O trabalho analisa o desempenho dos modelos clássicos de regressão logística contra modelos de *machine learning* de *boosting* (*XGBoost* e *Extreme GB*). Sendo os modelos de ML superiores ao método estatístico clássico.

O trabalho do (LIMA, 2023) é sobre a aplicação de algoritmos de machine learning para prever a inadimplência de clientes de uma empresa brasileira do setor de varejo. Foram comparados *K-Nearest Neighbors*, *Random Forest*, *Symbolic Regression* e *Support Vector Machine*. Vale destacar além de técnicas de balanceamento de classes *SMOTE* e *IHT* para o balanceamento das classes adimplente e inadimplente. Sendo que os modelos deram uma grande melhora ao utilizar esses métodos. Sendo o modelo *random forest* em conjunto com a técnica de *SMOTE* a melhor combinação para classificação.

Os modelos estatísticos são amplamente utilizados em várias áreas e são imprescindíveis na questão de inadimplência. Esses modelos visam maximizar lucros ao prever inadimplências potenciais, auxiliando na tomada de decisões estratégicas. O poder desses modelos está em ajudar as equipes decisoras a maximizar lucros, em vez de focar apenas na maximização de acertos ou na minimização de custos (BARTH, 2004). Eles fornecem uma boa base para avaliar riscos e determinar tomadas de decisão, seja para a concessão de crédito ou na escolhas de mercado na área de seguros.

3 FUNDAMENTAÇÃO TEÓRICA

3.1 INADIMPLÊNCIA

Cada linha do nosso *dataset* representa uma parcela de uma empresa que realizou um seguro por meio de nossa corretora. E uma empresa é considerada inadimplente quando possui a *flag* "SIM" na coluna "Esteve_Inadimplente?" da base de dados. Essa coluna é preenchida com base no histórico de pagamento das parcelas de seguros contratados pelos clientes. Caso o cliente tenha alguma parcela que esteja ou já esteve inadimplente — ou seja, com mais de 30 dias de atraso no pagamento e com confirmação da seguradora de que o valor não foi recebido —, a coluna é preenchida com "SIM". Se todas as parcelas foram pagas em dia ou nunca houve atraso, a coluna é marcada como "NÃO". Essa coluna será nossa variável *target*, que utilizaremos para a classificação de inadimplência nos modelos.

3.2 MODELOS

3.2.1 Regressão Logística

A regressão logística é uma das técnicas estatísticas mais utilizadas no mercado para desenvolvimento de modelos de *credit scoring* e análise de inadimplência (THOMAS, 2009). Isso se dava pois, tinha uma cultura forte da difusão dessa técnica; não necessita de uma distribuição normal multivariada para as variáveis independentes; é de fácil implementação, pois várias ferramentas estatísticas já tem os pacotes prontos para uso; e é uma ferramenta poderosa para a discriminação de dados binários (ROSA, 2000).

A Regressão Logística assume que a relação entre a probabilidade de ocorrência de uma classe binária (bom pagador ou mau pagador em nosso caso) e os atributos do modelo é expressa por uma razão de chances (odds ratio) (NISKIER SAADIA, 2020). Essa razão varia de 0 a infinito, indicando que valores menores que 1 estão associados a uma menor probabilidade de ocorrência da classe dependente, enquanto valores superiores a 1 aumentam essa probabilidade proporcionalmente à magnitude da razão.

É um modelo que funciona bem para dados categóricos como é o caso do nosso dataset. Colunas como porte da seguradora, região, tipo de produto etc, ou seja, variáveis categóricas é utilizado a técnica de dummy variables (BARTH, 2004).

A função de regressão logística é dada por:

$$\frac{p}{1-p} = \beta_0 + \beta_1 \cdot X_1 + \beta_2 + \beta_3 \cdot X_2 \dots \beta_n \cdot X_n$$

Em que:

p = é probabilidade de ocorrer a adimplência;

$(1 - p)$ = probabilidade de ocorrer inadimplência;

β_0 = o intercepto y quando todas as variáveis de entrada independentes forem iguais a 0;

$\beta_1 X_1$ = o coeficiente de regressão (β_1) da primeira variável independente (X_1), o valor do impacto da primeira variável independente na variável dependente;

$\beta_n X_n$ = o coeficiente de regressão (β_n) da última variável independente (X_n), quando houver vários valores de entrada;

Já a estimativa dos coeficientes de β_1 é dada pela máxima verossimilhança.

Ou seja, se considerarmos que as observações classificadas em 2 categorias mutualmente exclusivas 0 ou 1. 1 para clientes bons pagadores e 0 para mau pagadores. A variável Y assume 1 (se o i-ésimo indivíduo pertence a categoria bom pagador) ou 0 (se o cliente i-ésimo pertence à categoria de mau pagador (GONÇALVES; GOUVÊA; MANTOVANI, 2013).

Entretanto, esse modelo vem perdendo espaço para outras técnicas mais avançadas. Com o avanço de técnicas de machine learning, novas formas de solucionar o problema de inadimplência surgiram.

3.2.2 Machine Learning

O machine learning foi definido por Arthur Samuel, no final dos anos 50, como um campo de estudo que garante aos computadores a capacidade de aprender de forma autônoma após serem programados para essa tarefa. Ele pode ser entendido como uma subcategoria da inteligência artificial, um sistema que é capaz de analisar uma grande quantidade de dados através da estatística, identificando os padrões existentes para posteriormente fazer previsões ou determinar relações (Pimentel & Omar, 2006). (COELHO; AMORIM; CAMARGOS, 2021, p. 99)

Diante do modelo clássico de regressão logística, utilizaremos técnicas de machine learning. Conceitualmente, os algoritmos de machine learning podem ser encarados como uma busca em um espaço de padrões, guiada pela experiência de treinamento afim de encontrar uma maneira de otimizar métricas de desempenho (JORDAN; MITCHELL, 2015).

Nos últimos anos, o *machine learning* tem atraído um enorme foco e interesse de pesquisadores e tecnólogos, que estão tentando implementar vários modelos e algoritmos de machine learning em campos que tornarão diversas tarefas importantes e a vida do cidadão comum muito mais fácil.

O desenvolvimento de novas tecnologias e computadores superpoderosos, com um poder de processamento avançado e a redução do custo de processamento de dados, possibilitou a adoção de técnicas de machine learning em diversas áreas, como saúde, ciência, sistemas financeiros, comércio, entre outras (JORDAN; MITCHELL, 2015). Essas técnicas têm auxiliado diferentes setores na tomada de decisão baseada no processamento massivo de dados. Problemas que podem ser resolvidos com a melhoria de alguma medida de desempenho ao executar tarefas específicas são abordados por meio de experiências de treinamento (JORDAN; MITCHELL, 2015). É um conceito que possibilita que máquinas aprendam com o mundo real, através de interações, observações e comportamentos. Assim como os seres humanos aprendem e agem. Contudo, as tarefas são otimizadas pelo grande volume de dados disponível (BARBAGLIA; MANZAN; TOSETTI, 2023).

Isso só é possível graças à grande quantidade de dados, os chamados Big Data, que nas últimas duas décadas têm sido extraídos e armazenados em volumes sem precedentes na história. Esses dados são utilizados em soluções de machine learning, com uma granularidade que permite desenvolvermos soluções personalizadas. O avanço tecnológico tem possibilitado a coleta massiva de dados de dispositivos como celulares, além do desenvolvimento de computadores cada vez mais

poderosos para processar essa enorme quantidade de informações. Assim, as inovações tecnológicas e a abundância de dados têm sido fundamentais para impulsionar o campo do machine learning e suas aplicações em diversas áreas.

Normalmente o nome dado a um modelo de machine learning é a combinação de estrutura de dados, design, estimadores, mecanismo de conjunto e mais (BARBAGLIA; MANZAN; TOSETTI, 2023). Em nosso estudo utilizaremos 2 método de machine learning de ensemble. Métodos de ensemble combinam previsões de vários estimadores de base trabalhando juntos, a fim de melhorar a generalização e robustez em um único estimador (“1.11. Ensembles”, [s.d.], n. Acessado em: 14/12/2024).

3.2.2.1 Randon Forest


Antes de entrarmos precisamente no Randon Forest é importante dar um passo atrás e explicarmos Decicion Tree. Pois, o modelo de Randon Forest nada mais é do que várias árvores, do modelo Decision Tree, trabalhando em conjunto.

O algoritmo de árvore de decisão serve tanto para regressão quanto, para o nosso problema, para classificação. São representações simples e versáteis do conhecimento. Ele gera uma estrutura como uma árvore classificando as instâncias. Em que uma o rótulo das classes é representado por nós folhas e os galhos representam os resultados das perguntas feitos aos nós folhas (MADAAN et al., 2021).

Ela faz a divisão dos dados através da priorização das variáveis mais informativas para a variável resposta. O modelo é coloca nos primeiros nós folhas as variáveis mais importantes e vai separando os dados para as variáveis menos relevantes. De forma a separar os dados, com base na variável resposta, da maneira mais eficiente possível.

Na Figura 1 podemos ver um modelo de estrutura de uma árvore de decisão. Onde podemos ver o primeiro nó raiz como a pergunta “Vou a praia hoje?” e as respostas a pergunta vão dividindo os dados em duas respostas possíveis, sim ou não. “Vou a praia hoje”, **se** estiver sol, **então** sim ou **se** não estiver sou **então** não. Até o final dos dados ou até que o usuários pare as divisões ao “podar” a árvore fazendo com que não tenha overfitting. Assim, podemos ver que as árvores de decisão são representadas por regras do tipo se-então (if-then) (LE MOS; STEINER; NIEVOLA, 2005).

Figura 1: Exemplo de estrutura de uma árvore de decisão



Fonte: Elaborado pelo autor

Esse exemplo de ir a praia é uma maneira simples, apenas para ilustrar. Mas no caso de análise de inadimplência os dados vão sendo divididos até chegarmos a melhor divisão nos nós folhas. Existem várias maneiras de um nó folha selecionar qual a divisão fazer entre os dados na hora de dividi-los. Existem duas medidas de impureza para índice calcular as divisões dentro do nós folhas. O índice de Gini que busca diminuir a impureza entre os nós; a entropia que também mede a impureza.

O índice de Gini é definido por:

$$Gini = \sum_k P_{mk}(1 - P_{mk})$$

Em que:

- $\sum_k$ é a somatória é feita ao longo de todas as classes k.
- P_{mk} é a proporção (probabilidade) de exemplos que pertencem à classe k no nó m.

Já a entropia cruzada é dada por:

$$Entropy = - \sum_k p_{mk} \log(P_{mk})$$

Em que:

- $\sum_k$ é a somatória é feita ao longo de todas as classes k.
- P_{mk} é a proporção (probabilidade) de exemplos que pertencem à classe k no nó m.

- $\log(p_{mk})$ é o logaritmo (na base 2) da proporção P_{mk}

A principal vantagem deste modelo, Decision Tree, é a fácil interpretação de seus resultados. Compreender como ele toma as decisões levando em consideração os atributos mais relevantes (LEMONS; STEINER; NIEVOLA, 2005). Como podemos ver no exemplo da figura 1 é fácil compreender o caminho que o modelo tomou para chegar ao resultado final.

Os modelos de Random Forest são modelos do tipo *bagging* que usam uma combinação dos preditores de árvore de decisão de modo que cada árvore depende dos valores de um vetor aleatório amostrado de forma independente e com a mesma distribuição para todas as árvores na floresta. Estimadores internos monitoram o erro, a força e a correlação, e são usadas para mostrar a resposta ao aumento do número de *features* utilizadas na divisão. Os estimadores internos também são usados para medir a importância das variáveis (BREIMAN, 2001). Podem ser utilizados tanto em problemas de classificação quanto de regressão (LIMA, 2023).

Sua ideia principal é diminuir a correlação de um conjunto de árvores de decisão com baixo valor de classificação para melhorar a acurácia do modelo, sem que aumente a variância (SANTOS, 2022). É um método com alta acurácia em suas previsões, tem um bom funcionamento mesmo em dados desbalanceados, necessita de um baixo poder de processamento e se adapta bem para dados incompletos em parte da base de dados (LIMA, 2023).

Dado um conjunto de classificadores $\{h(x, \theta_n, k=1, \dots)\}$ onde o θ_k são um vetores independentes de outros vetores passados $\theta_1, \theta_2, \dots, \theta_{k-1}$ com a mesma distribuição aleatória. Resultando em um classificador $h(x, \theta_k)$ onde x é um vetor de entrada (BREIMAN, 2001). Após um número n de árvores serem geradas pelo algoritmo com a ordem aleatória entre os nós. Elas votam pela classificação mais popular e aquela com maior frequência é escolhida (LIMA, 2023).

Devido à lei dos grandes números explica por que as florestas aleatórias são menos suscetíveis a *overfitting* à medida que mais árvores são adicionadas, mas sim atingem um valor limite para o erro de generalização (BREIMAN, 2001). À medida que o número de árvores aumenta, para quase todas as sequências, os resultados convergem. Isso significa que adicionar mais árvores a uma floresta aleatória melhora a robustez e a precisão do modelo até um ponto em que o erro de generalização se estabiliza. Além dessas vantagens, (FORTI, 2018) explica que a redução da correlação entre as árvores é ocasionada pela reamostragem dos registros e das variáveis.

As vantagens de se usar o random forest segundo (MADAAN et al., 2021, p. 5) são: "(...) Immunity to overfitting. Accurate classification or regression. More efficient on large databases." Dessa forma, o random forest se mostra como uma boa solução por sua boa capacidade de generalização e eficiência em grandes bases de dados.

3.2.2.2 XGBoost

Outro algoritmo de ensemble que usaremos no presente trabalho é o Extreme Gradient Boosting (XGBoost). Existem vários métodos de boosting, mas utilizaremos este por apresentar bom desempenho em uma grande variedade de tipos de dados. Os métodos de boosting, incluindo o XGBoost, se destacam em datasets de médio porte, pois rodam com relativa rapidez e não requerem muito esforço ou tempo para ajustar os parâmetros (DAOUD, 2019).

Proposto por Chen (2016) o modelo se assemelha ao Random Forest, pois também utiliza vários estimadores de árvores de decisão como base. Contudo, diferentemente do Random Forest, que utiliza a abordagem de bagging, este modelo utiliza a abordagem de boosting. Nos algoritmos de bagging, os classificadores mais simples, como as árvores de decisão no caso do Random Forest, são treinados separadamente e depois agregados para a classificação a partir da média de cada árvore de decisão. Nos algoritmos de boosting, também são utilizados classificadores simples que são treinados separadamente, entretanto, a agregação é feita por meio de uma ponderação do desempenho de cada modelo. Os modelos são treinados sequencialmente e cada estimador trabalha de forma a diminuir o erro do estimador anterior (COELHO; AMORIM; CAMARGOS, 2021).

A fim de minimizar a função de perda em cada um dos classificadores. “A função objetivo é continuamente minimizada a partir da utilização de múltiplas combinações de árvores aleatoriamente estimadas, até se atingir o mínimo global, que minimiza o erro de estimação” (COELHO; AMORIM; CAMARGOS, 2021, p. 101). Contudo, outros métodos de regressão podem ser utilizados em conjunto com as árvores de decisão (COELHO; AMORIM; CAMARGOS, 2021). O modelo é muito popular por oferecer resultados robustos, sendo um dos modelos com maior acurácia em resolução de problemas diversos (BARBAGLIA; MANZAN; TOSETTI, 2023).

Como já dito anteriormente, o modelo de XGBoost é mais rápido e robusto que outros modelos de boosting. Isso se dá porque ele usa uma nova técnica de regularização diminui riscos de overfitting (DAOUD, 2019) e melhor o desempenho. A técnica de regularização, para diminuir a função de perda é feita adicionando um novo termo à função.

A função de perda regularizada no XGBoost é expressa como:

$$L(\varphi) = \sum l(\hat{y}_i, y_i) + \sum \Omega(f_k)$$

$$\Omega(f) = \gamma T + \frac{1}{2} \lambda \|w\|^2$$

Onde:

- L é uma função de perda convexa diferenciável que mede a diferença entre a predição $\hat{y}_i$ e o alvo y_i .
- O segundo termo Ω penaliza a complexidade do modelo, ou seja, as funções de árvore de regressão.

A adição do termo de regularização ajuda a suavizar os pesos finais aprendidos, diminuindo o risco de overfitting. O objetivo da regularização é selecionar um modelo que empregue funções simples e preditivas (CHEN; GUESTRIN, 2016).

O modelo do XGBoost cria-se um primeiro modelo F_0 que prediz a variável alvo. Um novo modelo h_1 é criado para complementar o valor residual do primeiro modelo $F_1(Y - F_0(X))$, onde Y são os valores reais e $F_0(X)$ os valores preditos. Então, os modelos F_0 e h_1 são combinados gerando o modelo F_1 , uma versão aprimorada de F_0 (COELHO; AMORIM; CAMARGOS, 2021).

O XGBoost é amplamente reconhecido por sua escalabilidade, flexibilidade e versatilidade excepcionais. Um dos fatores mais importantes por trás do sucesso do XGBoost é sua

escalabilidade em vários os cenários. O sistema executa mais de dez vezes mais rápido do que soluções populares existentes em uma única máquina e pode lidar com bilhões de exemplos em configurações distribuídas ou com memória limitada.

Em todos os trabalhos lidos de comparação de modelos seja para análise de inadimplência em risco de crédito ou para inadimplência no setor de varejo. Sempre que utilizaram métodos de machine learning ele se saiu melhor que regressão logística, contudo, vale lembrar que é impossível declarar um único método melhor dentre todos os outros, pois para cada caso um modelo pode se sair melhor que outro (MADAAN et al., 2021)

Neste trabalho usaremos o pacote do scikit learn para os modelos de regressão linear e random forest. Já, para o modelo do XGBoost usaremos o pacote próprio do XGBoost.

3.3 BALANCEAMENTO DE DADOS

Um problema comum ao lidar com modelos estatísticos é trabalhar com dados em que a variável resposta possui classes desbalanceadas. Uma base de dados é considerada desbalanceada quando a variável alvo tem muito mais casos de uma determinada classe do que de outras (CORDEIRO, 2020). Existem três tipos possíveis para se tratar esse tipo de problema: undersampling, oversampling e uma combinação de ambos, over + under-sampling. Esse é exatamente o nosso problema. Temos muito mais respostas casos adimplentes que inadimplentes em nossa base. O que é até esperado, visto que um negócio precisa muito mais de clientes bons pagadores para continuar a operar.

Geralmente, o problema de conjuntos de dados desbalanceados ocorre quando uma classe representa um conceito circunscrito, enquanto a outra classe representa o contraponto desse conceito, de modo que exemplos da classe contraponto superam em número os da classe positiva (BATISTA et al.). Este tipo de dado é comum, por exemplo, em bancos de dados de registros médicos em que há uma grande quantidade de pacientes saudáveis em relação aos que tem a doença, ou bancos de dados para concessão de crédito.

Por exemplo, o algoritmo 1-NN pode classificar incorretamente muitos casos da classe minoritária porque os vizinhos mais próximos desses casos são exemplos pertencentes à classe majoritária. Da mesma forma, uma árvore de decisão tende a escolher sempre o galho que divide para o lado majoritário.

Para ambas os métodos utilizamos a técnica de reamostragem randômica:

- Oversampling: A replicação aleatória de exemplos de classes minoritárias para equilibrar a distribuição.
- Undersampling: A eliminação aleatória de exemplos da classe majoritária para alcançar um balanceamento adequado.




Figura 2: Distribuição de classes na base de dados do presente trabalho

3.3.1 Undersampling

O undersampling consiste em fazer uma subamostragem na classe majoritária, de modo que a equilibrar as classes. Essa técnica é mais adequada quando o conjunto de dados é bastante grande, pois assume-se que existem registros redundantes da classe majoritária. No entanto, para bases de dados pequenas, o undersampling pode não ser indicado, pois pode resultar na perda de informações relevantes no ajuste dos modelos (CORDEIRO, 2020, p. 22). No nosso caso decidimos testar a técnica, pois temos uma quantidade considerável de dados.

Para a reamostragem dos dados, utilizamos a biblioteca imbalanced-learn e a função RandomUnderSampler. As técnicas de subamostragem controlada reduzem o número de observações das classes majoritárias para um número especificado pelo usuário. No nosso caso, diminuimos a classe majoritária até que a classe minoritária representasse pelo menos 50% do total da classe majoritária.

Vale destacar que, neste caso, o algoritmo cria um novo conjunto de dados em que o número de amostras nas classes alvo é reduzido, mas as amostras remanescentes são geradas a partir do conjunto original, e não apenas selecionadas dele (“3. Under-sampling — Version 0.13.0”, Acessado em: 15/01/2025).




Figura 3: Classes reamostradas utilizando o método de undersampling

3.3.2 Oversampling

Oversampling consiste em fazer uma superamostragem da classe minoritária através de similaridade e bootstrapping (reamostragem) através de métodos não heurísticos (randomicos). (CORDEIRO, 2020).

Uma maneira simples de combater esse problema é gerar novas amostras nas classes sub-representadas. A estratégia mais simples é gerar novas amostras por meio de amostragem aleatória com reposição das amostras disponíveis. Entretanto, isso pode gerar um problema de overfitting. Já que o método de faz cópias exatas dos exemplos das classes minoritárias. Desta forma, um classificador simbólico pode construir regras que são aparentemente precisas, mas que na verdade abrangem apenas um exemplo replicado (“2. Over-sampling — Version 0.13.0”, [s.d.] Acessado em 14/01/2025).

Para evitar esse problema, utilizamos a técnica de SMOTE (Synthetic Minority Over-sampling Technique). A técnica de SMOTE, assim como outras técnicas de superamostragem, cria observações artificiais para ampliar a classe minoritária. Contudo, o algoritmo seleciona aleatoriamente uma observação x da classe com menos representantes e, em seguida, cria uma nova observação artificial entre x e outras observações na sua vizinhança mais próxima. Esse processo é repetido até que as classes estejam equilibradas. (CORDEIRO, 2020)




Figura 4: Classes reamostradas utilizando a técnica de over-sampling

3.3.3 Oversampling + Undersampling

Over + undersampling: Consiste na combinação das duas estratégias.

3.4 MÉTRICAS DE DESEMPENHO

Nossos modelos tem 4 tipos de respostas possíveis: “Positivo Verdadeiro (PV): inadimplente classificado como inadimplente; ii. Positivo Falso (PF): bom pagador classificado como inadimplente; iii. Negativo Verdadeiro (NV): bom pagador classificado como bom pagador; iv. Negativo Falso (NF): inadimplente classificado como bom pagador.” (LIMA, 2023, p. 18) Para analisarmos essas possíveis previsões utilizaremos as medidas de acurácia, precisão, revocação, f1-score, aliadas à matriz de confusão.

A acurácia mede o quanto o modelo é capaz de acertar os valores corretos, independentemente de VP ou VF. E é dado por (SANTOS, 2022):

$$Acurácia = \frac{VP + VN}{VP + FP + VN + FN}$$

A sensibilidade (ou *recall*) é a métrica que avalia a capacidade dos modelos de identificar corretamente os valores positivos (VP). Essa medida varia de 0 a 1, em que valores mais próximos de 1 indicam um melhor desempenho do modelo (SANTOS, 2022). A medida é dada por:

$$Recall = \frac{VP}{VP + FN}$$

A precisão (ou *precision*) mede a proporção de verdadeiros positivos em relação ao total de casos classificados como positivos pelo modelo (verdadeiros positivos + falsos positivos). Ela mede a capacidade do modelo de acertar os casos positivos, considerando também os erros de classificação (falsos positivos) (SANTOS, 2022). A precisão é dada por:

$$Precision = \frac{VP}{VP + FP}$$

Já a matriz de confusão é uma forma visual, em formato de tabela, que permite visualizar o desempenho de classificação do modelo, comparando as previsões verdadeiras ou falsas do modelo com os valores reais. Por exemplo:




Figura 5: Exemplo de matriz de confusão. Fonte: Elaborado pelo autor

4 RESULTADOS

4.1 ANÁLISE EXPLORATÓRIA

Nosso dataset traz informações de parcelas de seguros B2B (Business to Business), de produtos diversos, com venda efetivada pela corretora de seguros de 2022 até 2024. Ele contém informações detalhadas sobre parcelas de seguros vendidas pela corretora, englobando dados sobre seguradoras, tomadores (clientes), produtos adquiridos, número da parcela, quantidade de parcelas e valores relacionados, como comissão, prêmio e parcelas. Também a coluna *target* “Esteve_Inadimplente” que indica se aquela parcela esteve inadimplente ou não. Mesmo que a parcela não esteja mais inadimplente, se ela foi paga com atraso em qualquer momento, essa informação é registrada com a *flag* "SIM", caso contrário terá o valor de “NÃO”. A coluna *target* foi mapeadas, para melhor funcionalidade do modelo, e passa para 0 igual que nunca ficaram inadimplentes e 1 para inadimplentes.

Esses dados permitem que a corretora avalie o histórico de pagamentos dos clientes, identificando padrões de inadimplência e ajudando na tomada de decisões estratégicas. Além disso, a análise dessas informações pode auxiliar na criação de produtos mais adaptados às necessidades dos clientes, bem como na elaboração de políticas de precificação e cobrança mais eficazes. Em suma, este *dataset* traz informações importantíssimas para otimizar a operação da corretora e mitigar riscos financeiros.

Os dados já estavam em boa qualidade, apresentando poucos valores ausentes e nenhum incorreto. O processo de tratamento foi simples, consistindo em zerar os valores das parcelas que estavam nulos, por exemplo, e remover as apólices que foram canceladas por qualquer motivo. Várias colunas foram retiradas por não agregarem com ganho de informação para a variável resposta ou por serem redundantes. Essas ações garantem melhor funcionamento dos modelos que usaremos nos próximos capítulos.

Como observado, os dados estão desbalanceados. Apenas um pouco mais de 2% das apólices emitidas já estiveram inadimplentes. No entanto, considerando os valores não recebidos, o percentual é um pouco mais alto. O valor das parcelas inadimplentes totaliza quase 6% do total vendido pela empresa, o que representa um valor significativo, dado o volume de vendas da empresa.




Figura 6: Distribuição de valor inadimplente. Fonte: De autoria própria

Uma análise interessante é a do comportamento de inadimplência ao longo do tempo. Ao longo dos meses a inadimplência varia muito de mês para mês. Devido ao trabalho dos analistas que visam reverter aquela inadimplência. Então, se há um pico de inadimplência em 1 mês no outro a tendência é de queda. Entretanto, se agruparmos a inadimplência por trimestre podemos ver uma tendência de concentração no segundo semestre do ano (T3 e T4).

Para ganho de informação ao modelo criamos a coluna de “Trimestre”. Essa coluna consiste no número do trimestre que aquela parcela foi emitida. Criamos essa nova variável pois vimos que tem uma pequena concentração de valores inadimplentes nos terceiro e quarto trimestres. O que indica uma tendência de aumento nesses trimestres

Para aprimorar o modelo, criamos a coluna "Trimestre", que indica o número do trimestre em que cada parcela foi emitida. A introdução dessa nova variável foi motivada pela observação de uma pequena concentração de valores inadimplentes nos terceiro e quarto trimestres, sugerindo uma tendência de aumento de inadimplência nesses períodos. Essa adição visa fornecer aos modelos um ganho de informação.




Figura 7: Análise trimestral de comissão inadimplente. Fonte: Autoria própria

Para lidar com a colunas de nome de seguradoras e tipo de produto utilizamos o método one-hot-encoding. A técnica de pré-processamento consiste em transformar colunas categóricas em variáveis que podem ser utilizadas pelo modelo. Cada categoria distinta da variável é transformada em uma nova coluna binária. Ou seja, para cada valor único na variável categórica, é criada uma nova coluna que indicará com 1 (verdadeiro) ou 0 (falso). Por exemplo, na coluna “NOME_SEGURADORA_FINAL”, com os nomes de cada seguradora, a o nome da seguradora X se transformara na coluna X onde tem 1 para as parcelas daquela seguradora e 0 para parcelas que são de outras seguradoras. Isso se repetiu para a coluna outras colunas do tipo *object*.

Esta é a estrutura do nosso *dataset* final, sem o *one-hot-encoding*, para melhor entendimento é:

```

<class 'pandas.core.frame.DataFrame'>
Index: 1867279 entries, 2 to 1952062
Data columns (total 14 columns):
#   Column                                Dtype
---  -
0   VlReceitaEsperada                     int32
1   NrParcelas                           int32
2   GrupoProduto                         object
3   NOME_SEGURADORA_FINAL                 object
4   PeriodicidadePagamento               object
5   TipoOportunidade                     object
6   PremioBrutoModDiv                    int32
7   Parcela                              int64
8   ValorParcela                         int32
9   PeriodicidadeMes                      int64
10  TIPO_INADIMPLÊNCIA                   object
11  Esteve_Inadimplente?                  object
12  INADIMPLENTE?_num                     float64
13  trimestre                             int32
dtypes: float64(1), int32(5), int64(2), object(6)
memory usage: 178.1+ MB

```

Figura 8: Visão das colunas do dataset e seus respectivos tipos de dados.

Por motivo de segurança vários dados foram anonimizados para que não fosse possível identificar qualquer pedido. Colunas como como os nomes das seguradoras e nomes de clientes, número de pedido ou apólice etc. Qualquer dado que pudesse identificar a apólice segurada foi anonimizada. Contudo, ainda conseguimos tirar insights importantes dos dados que devemos dar atenção. E modelar sobre eles.

4.2 AVALIAÇÃO DOS MODELOS

Agora analisaremos o desempenho dos 3 modelos propostos em diferentes cenários. Dividiremos o comparativo entre os modelos em três formas diferentes. Primeiro, analisaremos os três modelos para dados desbalanceados, observando como cada um lida com a falta de balanço entre as classes. Em seguida, partiremos para os dados balanceados utilizando a técnica de *oversampling*. Posteriormente, examinaremos os dados balanceados utilizando a técnica de subamostragem *undersampling*. Por fim, faremos um comparativo dos três modelos nos três cenários.

O foco na avaliação dos modelos é maximizar os verdadeiros positivos (identificar corretamente os inadimplentes) e minimizar os falsos positivos (evitar classificar adimplentes como inadimplentes). O principal problema ocorre quando o modelo classifica como não inadimplente uma parcela que está inadimplente, pois isso impede a empresa de tomar ações preventivas, como entrar em contato previamente com o cliente, renegociar dívidas ou iniciar medidas legais, resultando em possíveis perdas financeiras. O que é menos danoso caso o modelo classifique uma parcela adimplente como inadimplente, a empresa pode gastar recursos desnecessários ao oferecer suporte, mas sem impactos financeiros diretos. Portanto, o maior risco está nos falsos negativos, que impedem a empresa de agir e causa possíveis perdas financeiras.

4.2.1 Modelos com dados desbalanceados

Inicialmente, após a aplicação dos tratamentos de pré-processamento para que o modelo possa funcionar, conforme detalhado no item anterior, os modelos de classificação foram estimados diretamente na base de dados desbalanceada, sem a realização de qualquer tratamento específico para o desbalanceamento de classes.

No *dataset* de treinamento, todos os modelos aparentam estar sofrendo de overfitting no *dataset* de validação. Ao ajustar os modelos em uma base de dados com classes desbalanceadas, os modelos predisseram uma muitos falsos negativos, ou seja, casos em que os clientes estavam inadimplentes, mas foram erroneamente classificados como adimplentes. Por outro lado, os modelos demonstraram alta precisão na classificação da classe majoritária, acertando quase todos os casos dessa categoria. Isso sugere que os modelos estão priorizando a classe majoritária o que era esperado ao lidar com bases desbalanceadas.

Como podemos ver o modelo de regressão logística teve um desempenho muito parecido tanto em validação quanto em teste. Na duas matrizes, de validação e teste, observa-se um grande número de verdadeiros negativos e um número muito baixo de falsos positivos, o que sugere que o modelo está acertando a maioria dos casos da classe majoritária. No entanto, o número de falsos negativos é consideravelmente alto, indicando que o modelo está falhando em prever corretamente a classe minoritária.




Figura 9: Matriz de confusão dados de validação Regressão Logística. Fonte: próprio autor




Figura 10: Matriz de confusão dados de teste Regressão Logística. Fonte: próprio autor

Já o modelo baseado em árvores de decisão apresenta um comportamento muito semelhante ao da regressão logística, embora com um desempenho um pouco superior. Assim como o método clássico, ele prioriza a classe majoritária durante a classificação, acertando a maioria dos valores VN. Embora esse modelo se saia melhor do que a regressão logística ao prever alguns valores de VP, ele ainda enfrenta dificuldades significativas com os FP, que são o nosso problema. Tanto nos

dados de validação quanto nos dados de teste, o modelo continua a cometer muitos erros em relação aos FP, com um desempenho ainda pior no conjunto de teste.




Figura 11: Matriz de confusão dados de validação Random Forest. Fonte: próprio autor




Figura 12: Matriz de confusão dados de teste Regressão Logística. Fonte: próprio autor

Por último, ao analisar o modelo *XGBoost* com os dados desbalanceados, não há muitas novidades em comparação aos modelos anteriores. Assim como a regressão logística e o *Random Forest*, o *XGBoost* apresenta um bom desempenho na classificação dos VN, mas um desempenho muito abaixo para as outras classes. Vale destacar que ele cometeu um pouco mais de erros do que o modelo *Random Forest* e, consequentemente, acertou menos valores de verdadeiros positivos (VP) em comparação ao modelo anterior. Isso reforça a tendência observada nos outros métodos, onde a classe majoritária é priorizada, enquanto a classe minoritária continua sendo negligenciada, evidenciando a necessidade de ajustes para melhorar a sensibilidade do modelo em relação aos casos positivos.




Figura 13: Matriz de confusão dados de validação XGBoosting. Fonte: próprio autor




Figura 14: Matriz de confusão dados de teste XGBoosting. Fonte: próprio autor

Assim, ambos os modelos de machine learning (Random Forest e XGBoost) apresentaram um desempenho superior ao modelo clássico de classificação (Regressão Linear), embora o desempenho de ambos ainda esteja muito abaixo do aceitável. Ao comparar os modelos, observa-se que os três alcançaram um recall de 100% para os VN, com o Random Forest destacando-se por ter um recall maior (23%) para os VP. No entanto, ao analisar a precisão, o modelo XGBoost se sai melhor, com 99% para os VN e 86% para os VP. Em resumo, em uma base de dados desbalanceada, o Random Forest demonstra uma vantagem por cometer menos erros nos casos de FP.

Avaliação de Modelos nos dados de Teste com Base Desbala...

Modelo	Classe	Recall	Precision
Regressão Logística	VN	100%	99.00%
	VP	0%	0.00%
Random Forest	VN	100%	100.00%
	VP	23%	56.00%
XGBoosting	VN	100%	99.00%
	VP	9%	86.00%

Tabela 1: Métricas de Desempenho de Modelos para Dados Desbalanceados: Acurácia, Precisão, Recall

4.2.2 Modelos Undersampling

Nos dados tratados com a técnica de undersampling, subamostramos a classe majoritária em aumentando o peso da classe minoritária. Utilizamos a técnica Random Sampler para realizar amostragens aleatórias. Nesse processo, treinamos e validamos os modelos com a base balanceada por meio da subamostragem, enquanto os testes foram realizados com os dados desbalanceados, simulando um cenário real em que os dados não estão equilibrados. Observamos que o comportamento dos modelos, treinados com a base balanceada, apresentou um desempenho superior em comparação aos modelos anteriores treinados diretamente com bases desbalanceadas, demonstrando a eficácia da técnica.

No caso da regressão logística, o modelo continuou apresentando um desempenho ruim, semelhante ao observado com os dados desbalanceados. Tanto nos dados de validação quanto nos dados de teste, o modelo cometeu um número grande de erros, especialmente em casos de falsos negativos. Ele previu incorretamente cerca de 97% dos casos como adimplentes, quando, na verdade, eram parcelas inadimplentes. Esse comportamento sugere que o modelo não está conseguindo aprender adequadamente os padrões da classe minoritária (inadimplentes), indicando uma limitação na capacidade de generalização.




Figura 15: Matriz de confusão dados de validação Regressão Logística undersampling. Fonte: próprio autor




Figura 16: Matriz de confusão dados de teste Regressão Logística undersampling. Fonte: próprio autor

Já o modelo *Random Forest* apresentou uma pequena melhora no desempenho em comparação aos resultados obtidos com os dados desbalanceados. Nos dados de validação, o modelo conseguiu aumentar a quantidade de acertos de VP e reduzir os erros de FN, mantendo uma alta taxa de acertos para VN. No entanto, esse bom desempenho não se repetiu nos dados de teste, onde o modelo não conseguiu generalizar bem. A taxa de erros de FP permaneceu muito alta, com mais de 97% dos casos de parcelas inadimplentes sendo erroneamente previstas como adimplentes. Isso

indica que, apesar da melhora na validação, o modelo ainda enfrenta dificuldades para generalizar em uma base de dados desbalanceada, como em cenários reais.




Figura 17: Matriz de confusão dados de validação Random Forest undersampling.
Fonte: próprio autor




Figura 18: Matriz de confusão dados de validação Random Forest undersampling.
Fonte: próprio autor

O terceiro modelo apresentou uma melhora considerável em comparação ao seu desempenho com os dados desbalanceados. Nos dados de validação, ele demonstrou o comportamento esperado de um bom modelo, acertando quase todos os VN, que pertencem à classe majoritária, e alcançando uma alta taxa de VP, ao mesmo tempo em que reduziu significativamente os FN. Além disso, o modelo manteve um bom desempenho nos dados de teste, acertando cerca de 90% dos casos de VP e reduzindo bastante os erros de FN. Esse resultado indica que o modelo conseguiu generalizar muito bem para dados desbalanceados, demonstrando uma capacidade relevante para lidar em cenários mais próximos da realidade.




Figura 19: Matriz de confusão dados de validação XGBoost undersampling. Fonte: próprio autor




Figura 20: Matriz de confusão dados de teste XGBoost undersampling. Fonte: próprio autor

Portanto, como pudemos observar, o XGBoost destacou-se como o melhor modelo ao generalizar de forma eficiente na base de teste com dados desbalanceados. Ele mostrou-se eficaz tanto em aumentar os acertos de VP quanto em reduzir os erros de FN e manteve quase 100% de acerto para os VN. Conforme a tabela abaixo, tanto o Random Forest quanto o XGBoost apresentaram desempenhos semelhantes em termos de *recall* (taxa de verdadeiros positivos). No entanto, ao analisar a *precision*, o XGBoost demonstrou superioridade, chegando a uma precisão de 85% para VP, enquanto o Random Forest obteve precisão de apenas 6%. Isso reforça a eficácia do XGBoost em lidar com dados desbalanceados e em fornecer previsões mais confiáveis.

Avaliação de Modelos nos dados de Teste com Base Undersampling			
Modelo	Classe	Recall	Precision
Regressão Logística	VN	100%	99,00%
	VP	2%	3,00%
Random Forest	VN	92%	100,00%
	VP	85%	6,00%
XGBoosting	VN	92%	93,00%
	VP	87%	85,00%

Tabela 2: Métricas de Desempenho de Modelos para Dados Balanceados Undersampling: Acurácia, Precisão, Recall

4.2.3 Modelos Oversampling

Agora nos dados tratados com a técnica de oversampling, superamostramos a classe minoritária, também, com o intuito de aumentar o peso da classe minoritária, contudo sem retirar informações da classe majoritária. Também utilizamos a a técnica de reamostragem randomica para realizar

amostragens aleatórias. Assim como no método anterior, treinamos e validamos os modelos com a base balanceada por meio da superamostragem, enquanto os testes foram realizados com os dados desbalanceados, afim de simular o estado real dos dados que não estarão equilibrados. Observamos que o comportamento dos modelos, treinados com a base balanceada com superamostragem, apresentou um desempenho muito parecido com a técnica de subamostragem e muito superior aos dados desbalanceados, demonstrando a eficácia da técnica. Contudo, os modelos de *machine learning* apresentaram um tempo de execução consideravelmente maior que os outros.

O modelo de regressão logística aplicado aos dados superamostrados apresentou um comportamento diferente dos cenários anteriores, com resultados mais equilibrados entre as classes previstas. Enquanto nos modelos anteriores os VN atingiam acertos próximos a 100% nos dados de validação, o atual registrou 62% de acertos para essa categoria, além de desempenho similar para as demais classes, com taxas de acerto e erro em torno de 45%, tanto para erro quanto para acerto. Curiosamente, esse padrão se repetiu na base de teste, indicando que o modelo generalizou adequadamente, mesmo com desempenho abaixo do ideal. Na prática, as previsões para os dados de teste foram: 52% de *Falsos Positivos (FP)* contra 47% de *Verdadeiros Positivos (VP)*, e 62% de VN frente a 37% de FN. Esse equilíbrio, embora reflita menor precisão, sugere uma distribuição mais homogênea das previsões, reduzindo o viés observado nas versões anteriores do modelo.




Figura 21: Matriz de confusão dados de validação Regressão Logística oversampling.
Fonte: próprio autor




Figura 22: Matriz de confusão dados de teste Regressão Logística oversampling. Fonte: próprio autor

O modelo Random Forest apresentou um comportamento semelhante ao da regressão logística, porém com desempenho ligeiramente superior. Nos dados de validação, o modelo mostrou bom desempenho ao identificar VN, mas dificuldade em discriminar VP, acertando apenas 60% dos casos de VP e registrando 40% de FN. Nos dados de teste, o padrão se manteve: o modelo alcançou quase 100% de acertos para VN e 59% para VP, mas persistiu com uma taxa elevada de FN (cerca de 40%). A consistência entre os resultados de validação e teste sugere que o modelo generaliza adequadamente para identificar FN o que é um problema.




Figura 23: Matriz de confusão dados de validação Random Forest oversampling. Fonte: próprio autor




Figura 24: Matriz de confusão dados de teste Random Forest oversampling. Fonte: próprio autor

O modelo XGBoost apresentou um desempenho promissor e diferente dos anteriores (tanto regressão logística e Random Forest, quanto do próprio XGBoost em outros cenários), aproximando-se do comportamento desejado para um modelo. Nos dados de validação, conseguiu identificar bem os VP, acertando mais de 90% dos casos, e VN, com 87% de acertos, além de reduzir significativamente os erros FN de 12% — ponto fraco em modelos anteriores — e manter os FP em patamares baixos. E principalmente o modelo demonstrou capacidade de generalização em dados de teste desbalanceados, mantendo o padrão: 91% de VP, 87% de VN, 12% de FN e 8,5% de FP. Essa consistência entre validação e teste indica que o XGBoost está se adaptando bem à complexidade dos dados, equilibrando sensibilidade (redução de FN) e especificidade (controle de FP). Embora ainda não seja ideal para implantação direta, os resultados sugerem um avanço considerável, especialmente na minimização de erros importantes e no bom trabalho frente ao desbalanceamento, apontando um bom caminho para refinamentos futuros.




Figura 25: Matriz de confusão dados de validação XGBoost oversampling. Fonte: próprio autor




Figura 26: Matriz de confusão dados de teste XGBoost oversampling. Fonte: próprio autor

Conforme podemos ver na tabela abaixo, o XGBoost destaca-se como o modelo mais promissor para previsão de inadimplência. Principalmente por sua capacidade de capturar casos positivos. Ele apresenta recall elevado para ambas as classes: 88% para VP (identificando a maioria dos clientes inadimplentes) e 91% para VN (classificando corretamente os adimplentes). Embora sua precisão para VP seja baixa (5%) — inferior até mesmo aos 12% do Random Forest —, esse trade-off é aceitável no cenário atual, onde o principal risco está em falsos negativos (FN), ou seja, deixar de identificar clientes com potencial de inadimplência. O XGBoost minimiza esse risco, detectando muito bem casos de positivos, mesmo que isso implique mais FP. Já o Random Forest, apesar de exibir maior equilíbrio entre métricas e precisão mais alta para VP, tem recall significativamente inferior (59%), o que o torna menos adequado para a necessidade específica de reduzir subnotificações. Portanto, o XGBoost aparece como uma boa opção para refinamentos futuros, dada sua eficácia em generalizar padrões complexos e priorizar a identificação de casos relevantes, alinhando-se ao objetivo de mitigar riscos de inadimplência não detectada.

Avaliação de Modelos nos dados de Teste com Base Oversampling			
Modelo	Classe	Recall	Precision
Regressão Logística	VN	62%	100,00%
	VP	48%	1,00%
Random Forest	VN	98%	100,00%
	VP	59%	12,00%
XGBoosting	VN	91%	100,00%
	VP	88%	5,00%

Tabela 3: Métricas de Desempenho de Modelos para Dados Balanceados Oversampling: Acurácia, Precisão, Recall

Na tabela abaixo, podemos ver um comparativo entre todos os cenários que trabalhamos até aqui e ver que, realmente, o modelo XGBoost, utilizando a técnica de *oversampling*, se saiu melhor que os demais modelos em outros cenários.

Avaliação de Modelos nos dados de Teste

modelo	classes	tipo_base	Precision	Recall	f1-score
Random Forest	accuracy	Desbalanceado	1,00	1,00	1,00
		Oversampling	0,79	0,79	0,79
		Undersampling	0,90	0,90	0,90
	NÃO	Desbalanceado	1,00	1,00	1,00
		Oversampling	0,71	0,98	0,82
		Undersampling	0,93	0,92	0,92
	SIM	Desbalanceado	0,60	0,27	0,37
		Oversampling	0,96	0,60	0,74
		Undersampling	0,84	0,86	0,85
Regressão Logística	accuracy	Desbalanceado	0,99	0,99	0,99
		Oversampling	0,62	0,62	0,62
		Undersampling	0,99	0,99	0,99
	NÃO	Desbalanceado	0,99	1,00	1,00
		Oversampling	1,00	0,62	0,77
		Undersampling	0,99	1,00	0,99
	SIM	Desbalanceado	0,00	0,00	0,00
		Oversampling	0,01	0,48	0,01
		Undersampling	0,03	0,03	0,03
XGBoost	accuracy	Desbalanceado	1,00	1,00	1,00
		Oversampling	0,91	0,91	0,91
		Undersampling	0,92	0,92	0,92
	NÃO	Desbalanceado	1,00	1,00	1,00
		Oversampling	1,00	0,91	0,96
		Undersampling	1,00	0,92	0,96
	SIM	Desbalanceado	0,79	0,08	0,15
		Oversampling	0,05	0,88	0,10
		Undersampling	0,05	0,86	0,10

Tabela 4: Métricas de Desempenho de Modelos: Acurácia, Precisão, Recall

5 CONCLUSÃO

O principal objetivo deste estudo foi aplicar técnicas consolidadas de previsão de inadimplência a um dataset de uma corretora de seguros. Para isso, comparamos o desempenho de algoritmos de machine learning selecionados com o modelo clássico de regressão logística, abordando o desafio de dados desbalanceados na variável-alvo (inadimplente ou não). Esse tipo de análise muito importante para empresas, pois oferece *insights* diretos para a mensuração de risco, como na decisão de comercializar produtos específicos, no cálculo de capital necessário para cobrir possíveis perdas e na gestão estratégica de clientes com histórico de mau pagador. Ao equilibrar a precisão e a sensibilidade dos modelos, buscamos fornecer ferramentas que auxiliem não apenas na mitigação de riscos, mas também na otimização de operações comerciais e financeiras.

A aplicação de técnicas de balanceamento de dados importantíssima neste estudo, dado que a desproporção entre classes (com predominância de clientes adimplentes) é uma característica comum em análises de inadimplência, especialmente em negócios com boa saúde financeira. Para mitigar esse desequilíbrio, utilizamos métodos de oversampling (superamostragem) e undersampling (subamostragem) de forma aleatória. Os resultados revelaram uma melhora significativa nos modelos quando os dados foram balanceados: nos três algoritmos testados, houve ganhos na capacidade preditiva. Contudo, enquanto o undersampling gerou desempenho elevado nos dados de validação — porém com baixa generalização para dados de teste —, o oversampling permitiu que os modelos mantivessem um desempenho consistente tanto na validação quanto no teste, indicando maior robustez.

O modelo XGBoost combinado com a técnica de oversampling mostrou-se eficaz não apenas ao equilibrar as classes, mas também ao preservar a diversidade dos dados, evitando *overfitting* e garantindo que os padrões aprendidos fossem aplicáveis a novos cenários. Nesse contexto, o modelo demonstrou capacidade de prever com precisão os valores verdadeiros, reduzindo significativamente os erros, especialmente nos FP, que é o tipo de erro que queremos evitar ao máximo em se tratando de inadimplência. O XGBoost aliado a técnica de reamostragem de dados mostra um bom desempenho em lidar com nosso conjunto de dados. Por isso ele mostra-se uma escolha promissora para aplicações práticas de avaliação de inadimplência.

Os modelos que utilizamos neste estudo ainda não estão completamente refinados e não estão prontos para serem colocados em produção. Há muito trabalho a ser feito para que possam ser utilizados de forma eficaz pela empresa na gestão de clientes inadimplentes. Entre as possíveis melhorias, podemos testar outras técnicas de balanceamento de dados, como SMOTE ou ADASYN, realizar *finetuning* de hiperparâmetros para otimizar o desempenho dos algoritmos e buscar dados mais informativos sobre as empresas que adquiriram seguros, como indicadores financeiros ou histórico de pagamentos, para entender melhor a saúde financeira dos clientes. Essas etapas podem nos ajudar muito em aumentar a precisão e a confiabilidade dos modelos, permitindo que a empresa tome decisões mais embasadas e estratégicas.

REFERÊNCIAS

1.11. Ensembles: Gradient boosting, random forests, bagging, voting, stacking. Disponível em: <<https://scikit-learn/stable/modules/ensemble.html>>. Acesso em: 15 dez. 2024.

2. Over-sampling — Version 0.13.0. Disponível em: <https://imbalanced-learn.org/stable/over_sampling.html>. Acesso em: 16 jan. 2025.

3. Under-sampling — Version 0.13.0. Disponível em: <https://imbalanced-learn.org/stable/under_sampling.html>. Acesso em: 15 jan. 2025.

BARBAGLIA, L.; MANZAN, S.; TOSETTI, E. Forecasting Loan Default in Europe with Machine Learning*. **Journal of Financial Econometrics**, v. 21, n. 2, p. 569–596, 1 jan. 2023.

BARTH, N. L. **Inadimplência. Construção De Modelos De Previsão.** 1ª edição ed. [s.l.] Nobel, 2004.

BATISTA, G. E. A. P. A.; PRATI, R. C.; MONARD, M. C. Study of the Behavior of Several Methods for Balancing Machine Learning Training Data. [s.d.].

BREIMAN, L. Random Forests. **Machine Learning**, v. 45, n. 1, p. 5–32, 1 out. 2001.

CHEN, T.; GUESTRIN, C. **XGBoost: A Scalable Tree Boosting System.** Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. **Anais...** 13 ago. 2016. Disponível em: <<http://arxiv.org/abs/1603.02754>>. Acesso em: 19 dez. 2024

COELHO, F. F.; AMORIM, D. P. DE L.; CAMARGOS, M. A. DE. Analisando métodos de machine learning e avaliação do risco de crédito. **Revista Gestão & Tecnologia**, v. 21, n. 1, p. 89–116, 15 mar. 2021.

CORDEIRO, T. V. B. Predição de default de empresas: técnicas de machine learning em dados desbalanceados. 11 nov. 2020.

DAOUD, E. A. Comparison between XGBoost, LightGBM and CatBoost Using a Home Credit Dataset. **International Journal of Computer and Information Engineering**, v. 13, n. 1, p. 6–10, 15 jan. 2019.

FARIAS, T. A. **Aplicação de Machine Learning em seguros de autos.** bachelorThesis—[s.l.] Universidade Federal do Rio Grande do Norte, 10 set. 2021.

Folder Institucional CNseg - 2024 | CNseg. Disponível em: <<https://cnseg.org.br/publicacoes/folder-institucional-c-nseg-2024>>. Acesso em: 7 ago. 2024.

FORTI, M. Técnicas de machine learning aplicadas na recuperação de crédito do mercado brasileiro. 8 ago. 2018.

GONÇALVES, E. B.; GOUVÊA, M. A.; MANTOVANI, D. M. N. Análise de risco de crédito com o uso de regressão logística. **Revista Contemporânea de Contabilidade**, v. 10, n. 20, p. 139–160, 7 ago. 2013.

JORDAN, M. I.; MITCHELL, T. M. Machine learning: Trends, perspectives, and prospects. **Science**, v. 349, n. 6245, p. 255–260, 17 jul. 2015.

LEMOS, E. P.; STEINER, M. T. A.; NIEVOLA, J. C. Análise de crédito bancário por meio de redes neurais e árvores de decisão: uma aplicação simples de data mining. **Revista de Administração - RAUSP**, v. 40, n. 3, p. 225–234, 2005.

LIMA, V. S. S. Aplicação de machine learning para previsão de inadimplência. 2023.

MADAAN, M. et al. Loan default prediction using decision trees and random forest: A comparative study. **IOP Conference Series: Materials Science and Engineering**, v. 1022, p. 012042, 19 jan. 2021.

NISKIER SAADIA, G. **USO DE TÉCNICAS DE MACHINE LEARNING NA PREVISÃO DO RISCO DE INADIMPLÊNCIA DE ALUNOS EM UMA INSTITUIÇÃO DE ENSINO SUPERIOR PRIVADA**. MESTRE EM ADMINISTRAÇÃO DE EMPRESAS - OPÇÃO PROFISSIONAL—Rio de Janeiro, Brazil: PONTIFÍCIA UNIVERSIDADE CATÓLICA DO RIO DE JANEIRO, 22 abr. 2020.

ROSA, P. DE T. M. **Modelos de 'credit scoring': regressão logística, 'chaid' e real**. text—[s.l.] Universidade de São Paulo, 2 out. 2000.

SANTOS, T. DE J. DOS. Aplicações de algoritmos de machine learning para previsão de inadimplência em concessão de crédito. 3 jun. 2022.

TEIXEIRA, N. **O que é uma corretora de seguros?** **Genebra Seguros**, 15 ago. 2022. Disponível em: <<https://www.genebraseguros.com.br/o-que-e-uma-corretora-de-seguros/>>. Acesso em: 7 ago. 2024

THOMAS, L. C. **Consumer Credit Models: Pricing, Profit and Portfolios**. 1st edition ed. Oxford ; New York: Oxford University Press, 2009.

VIEIRA, M. G. **Introdução aos Seguros**. [s.l.] Vida Economica Editorial, 2012.